Visão Computacional com CNNs e Transformers

Relatório técnico das atividades A1 a A4

Nathalia Machado
12 de outubro de 2026

Visão geral

Este relatório cobre as quatro atividades da disciplina: (A1) projeto livre com Vision Transformers, (A2) busca semântica em publicidade visual com CLIP, (A3) transfer learning com CNN pré-treinada e (A4) estudos de caso (4.1 radiografias de tórax e 4.2 tráfego urbano). Para cada atividade são apresentados a definição do problema, as decisões técnicas e suas justificativas, os resultados com métricas e gráficos e a análise crítica. Os notebooks `A1_vision_transformers.ipynb`, `A2_clip_ads16.ipynb`, `A3_cnn_kaggle.ipynb` e `A4_estudo_caso_raio_x.ipynb` acompanham este documento e foram executados do início ao fim em Google Colab; os resultados e figuras abaixo vêm dessas execuções.

Atividade	Tarefa	Dataset	Resultado principal
A1	ViT do zero, ViT-B/16 pré-treinado e ResNet-18	Fashion Product Images (Kaggle), 20 classes, 17.677 imagens	ViT-B/16: 94,38% de acurácia no teste; ViT do zero: 83,63%
A2	CLIP: ranking de objetos e busca semântica, sem treino	ADS-16: 301 anúncios (1.501 com fotos pessoais)	10 buscas: 5 corretas, 4 parciais, 1 falha
A3	ResNet-50 congelada (feature extraction)	Images Dataset (Kaggle), 7 classes, 1.803 imagens	98,89% de acurácia no teste (3 erros em 271)
4.1	Diagnóstico de projeto de triagem de COVID-19 e cGAN	COVID-19 Radiography Database (Kaggle)	Recall de COVID-19: 40,1% (caso original), 73,0% (melhorado), 77,9% (+ pesos), 66,1% (+ GAN)
4.2	Diagnóstico de projeto de tráfego urbano	(apenas análise escrita)	7 problemas e plano de ação

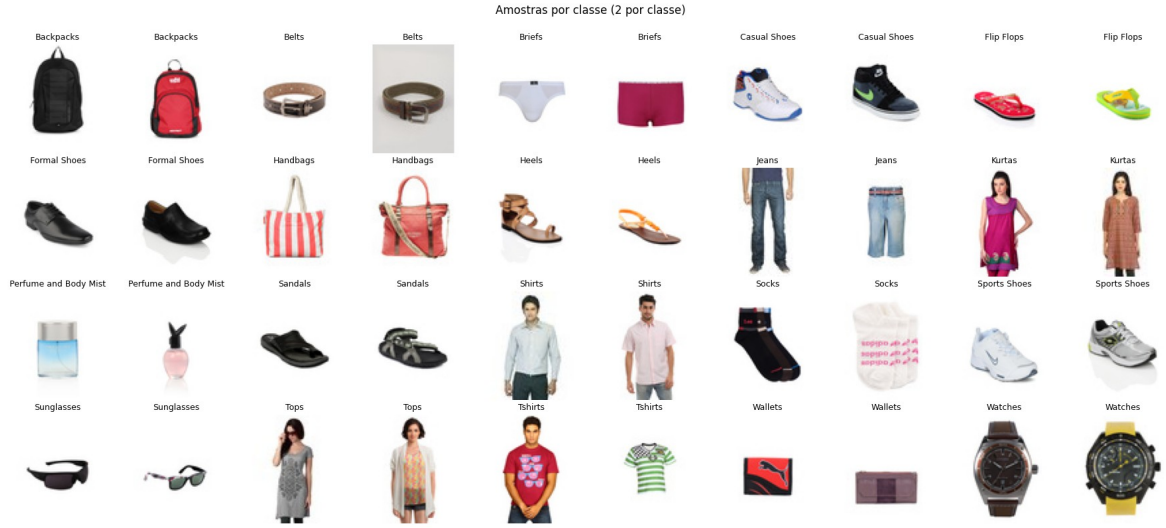
Atividade 1: Visão Computacional com Transformers (varejo)

1.1 Definição do problema

Problema. Classificar fotos de produtos de moda de um catálogo de e-commerce em seu tipo de artigo (`articleType`), como camisetas, relógios, bolsas e sapatos. No varejo, a classificação automática alimenta a organização do catálogo, a busca por categoria e a detecção de produtos cadastrados na categoria errada.

Dataset. *Fashion Product Images (Small)* (Kaggle), com 44.419 produtos com imagem e 142 tipos de artigo. Foram usadas as **20 classes mais frequentes**, com no máximo 1.000 imagens por classe (amostragem aleatória com semente fixa), totalizando **17.677 imagens**. As imagens originais (~60×80 px) foram preenchidas com branco até ficarem quadradas e redimensionadas para 80×80. A divisão é estratificada em **70% treino (12.373), 15% validação (2.652) e 15% teste (2.652)**; o teste foi usado uma única vez por modelo.

Hipótese de trabalho. Com 12 mil imagens, um ViT treinado do zero deve ficar atrás de modelos pré-treinados, porque o ViT não traz o viés indutivo de localidade das CNNs. O experimento mede essa diferença e investiga o que o modelo aprende a ponderar por meio dos pesos de atenção.



Amostras por classe do subconjunto (2 imagens por classe).

1.2 Decisões técnicas

ViT implementado do zero em PyTorch, com os componentes escritos explicitamente: `PatchEmbedding` (`Conv2d` com `kernel = stride = patch`), `ScaledDotProductAttention`, `AttentionHead`, `MultiHeadAttention` (cabeças independentes), `TransformerEncoderBlock` (LayerNorm *pre-norm*, MLP 4×, conexões residuais e *stochastic depth*), token `[CLS]` e embedding posicional aprendível. Cada componente passou em testes unitários (a atenção

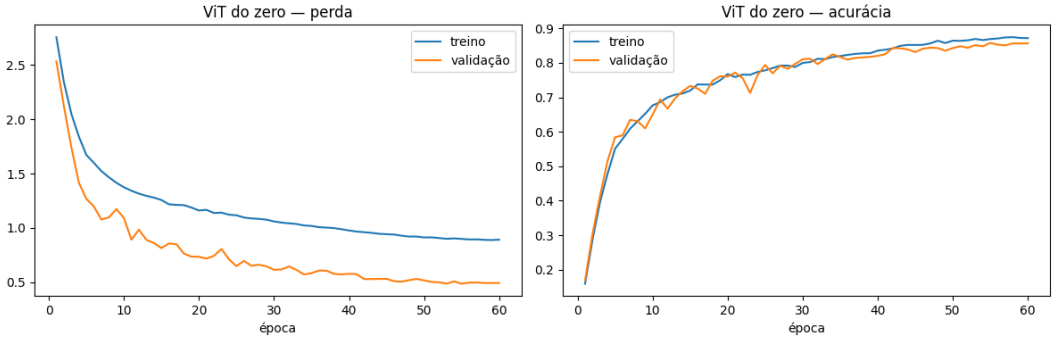
coincide com `F.scaled_dot_product_attention`, as linhas somam 1, as cabeças são independentes, o bloco com saídas zeradas é a identidade e o `[CLS]` é invariante à ordem dos patches somente sem embedding posicional).

Decisão	**Valor**	**Justificativa**
Patch / grade	8×8 em imagens 80×80 (10×10 = 100 patches + `[CLS]`)	Patches menores dão mais tokens e mais detalhe em imagens pequenas; 80 é divisível por 8
Tamanho do modelo	`dim=192`, 6 camadas, 3 cabeças (2,73 M de parâmetros)	Modelo pequeno, adequado a ~12 mil imagens; mais capacidade aumentaria o overfitting
Regularização	dropout 0,1, *drop path* até 0,1, *label smoothing* 0,1, *weight decay* 0,05	ViTs sem pré-treino sofrem com poucos dados
Augmentation	zoom 0,7 a 1,0, deslocamento de 10% e espelhamento horizontal	Peças de moda são em geral simétricas à esquerda/direita; sem flip vertical
Otimização	AdamW (sem *decay* em bias, LayerNorm, `[CLS]` e posição), LR 5e-4, *warmup* de 5 épocas e cosseno, 60 épocas, batch 128, fp16, *clipping* 1,0	Receita padrão de ViTs; seleção do melhor *checkpoint* pela validação
Pré-treinado	`google/vit-base-patch16-224-in21k` (ImageNet-21k), cabeça nova `Linear(768, 20)`, fine-tuning completo, entrada 224, LR 5e-5, 4 épocas, batch 64	LR baixo para não destruir os pesos pré-treinados
Baseline CNN	ResNet-18 (ImageNet), entrada 112, LR 5e-4, 8 épocas	Referência com viés indutivo de CNN e custo baixo

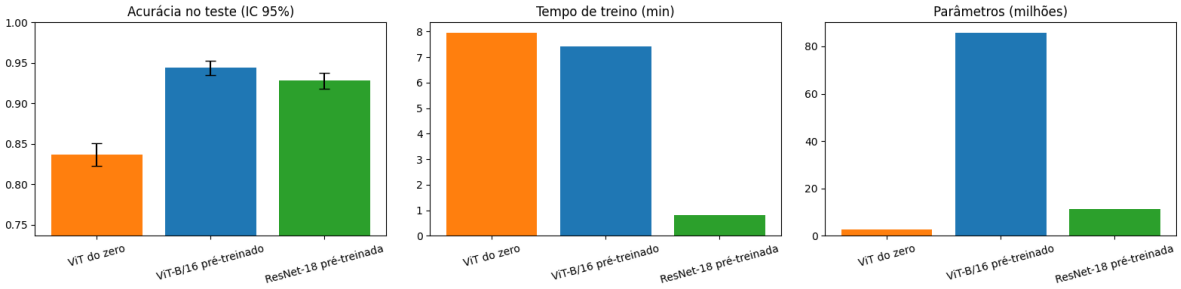
1.3 Resultados

Todos os modelos foram avaliados no mesmo conjunto de teste (2.652 imagens). O intervalo de confiança de 95% usa a aproximação normal da proporção.

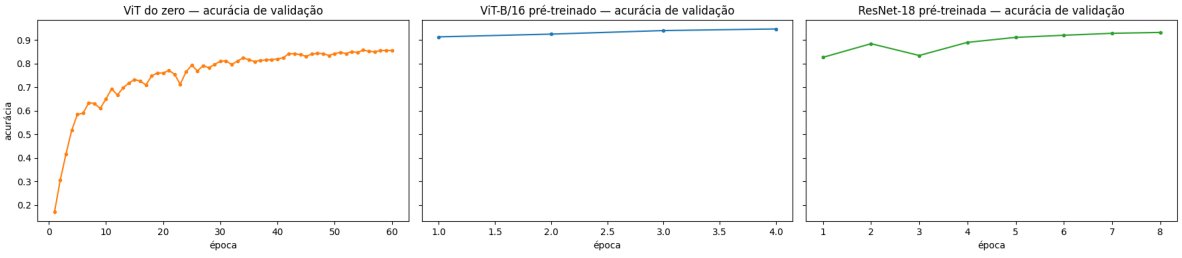
Modelo	Params	Treino	Melhor época	Acurácia val.	Acurácia teste (IC 95%)	F1 macro	Inferência
ViT do zero	2,7 M	8,0 min	55	0,8578	83,63% (±1,41)	0,842	6.613 img/s
ViT-B/16 pré-treinado	85,8 M	7,4 min	4	0,9476	**94,38% (±0,88)**	**0,947**	366 img/s
ResNet-18 pré-treinada	11,2 M	0,8 min	8	0,9329	92,80% (±0,98)	0,932	7.781 img/s



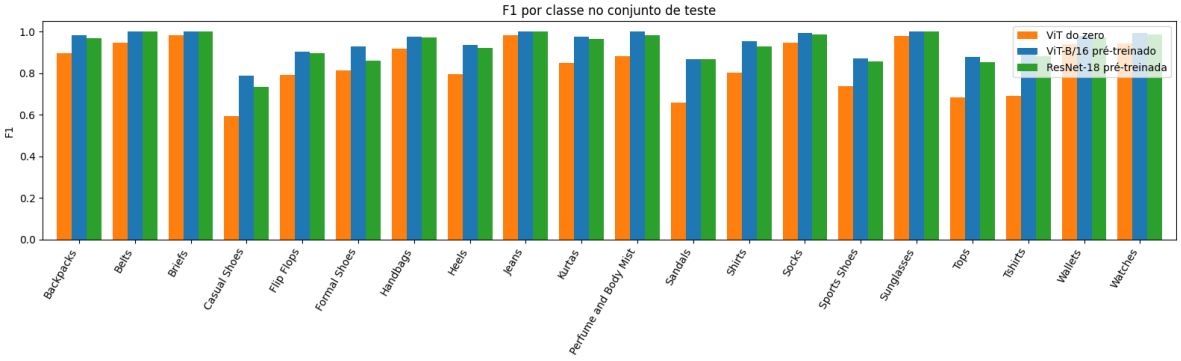
Curvas de perda e acurácia do ViT do zero.



Comparação final: acurácia no teste (com IC 95%), tempo de treino e parâmetros.

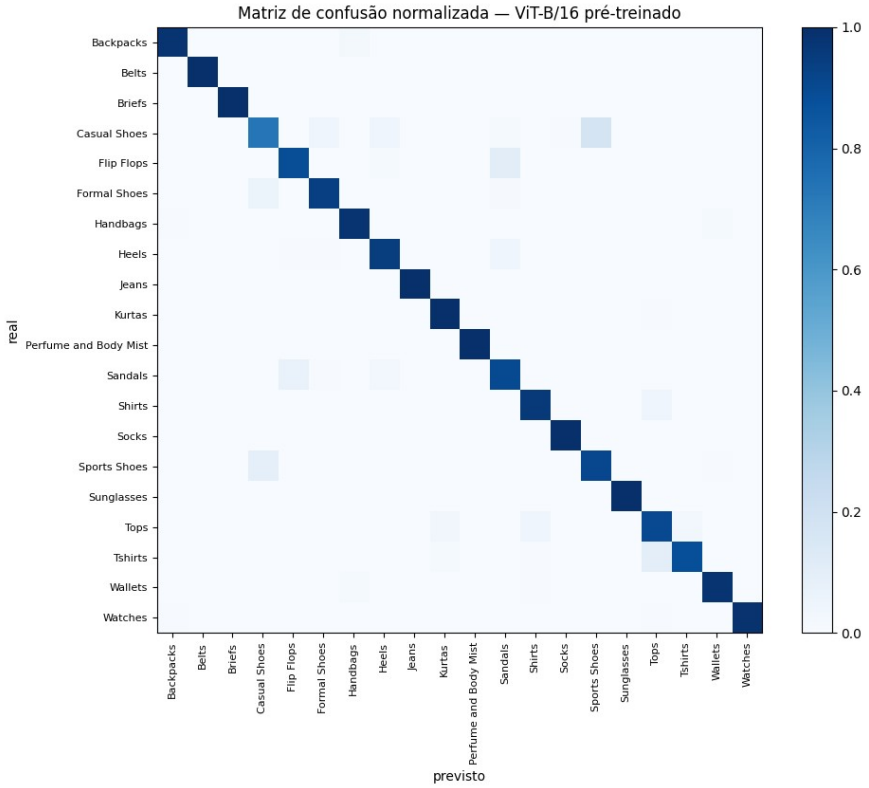


Acurácia de validação por época dos três modelos.



F1 por classe no conjunto de teste.

Maiores confusões. Nos três modelos o principal erro é entre calçados: *Casual Shoes* previsto como *Sports Shoes* (17 a 21% dos Casual Shoes), além de *Sandals* ↔ *Flip Flops* e *Casual* ↔ *Formal*. Na parte de cima, *Tshirts* ↔ *Tops* ↔ *Shirts* e, apenas no ViT do zero, *Tops* → *Kurtas* (22% dos Tops).



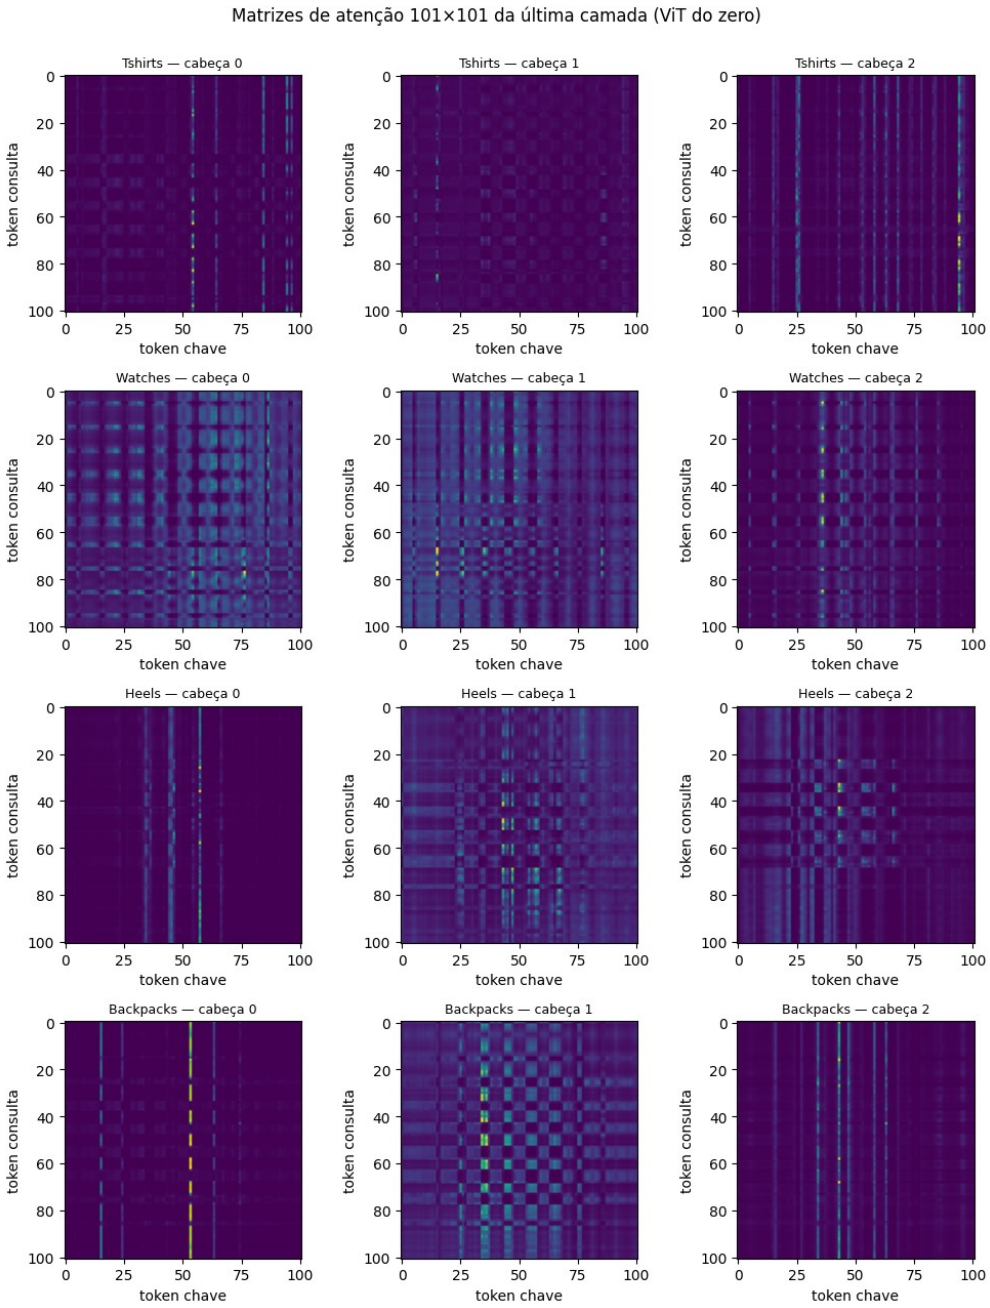
Matriz de confusão normalizada do ViT-B/16 pré-treinado (melhor modelo).



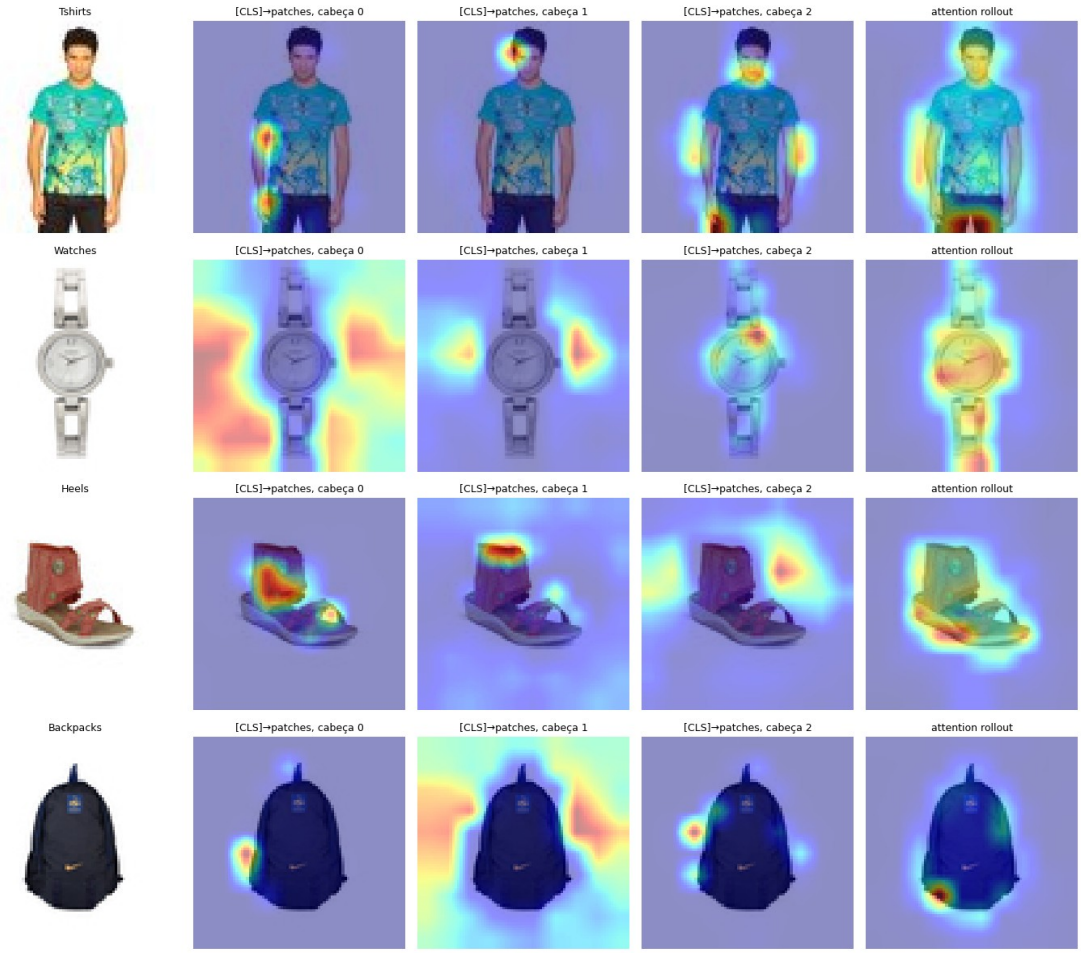
Exemplos de erros do melhor modelo.

1.4 Visualização e interpretação dos pesos de atenção

A atenção foi inspecionada de três formas: matriz 101×101 por cabeça na última camada do ViT do zero, atenção do `[CLS]` para os patches por cabeça e *attention rollout* (Abnar e Zuidema, 2020), que propaga a atenção por todas as camadas.

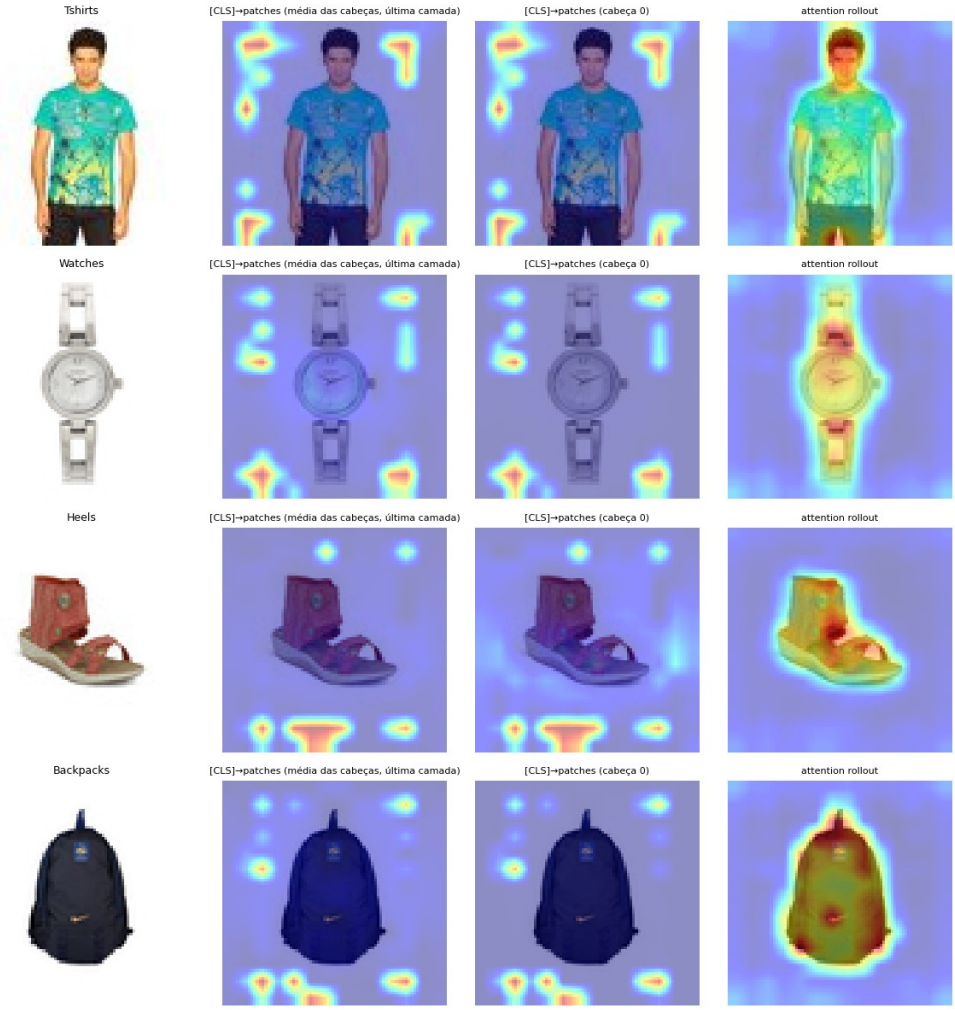


Matrizes de atenção 101×101 por cabeça (última camada, ViT do zero), para quatro classes.



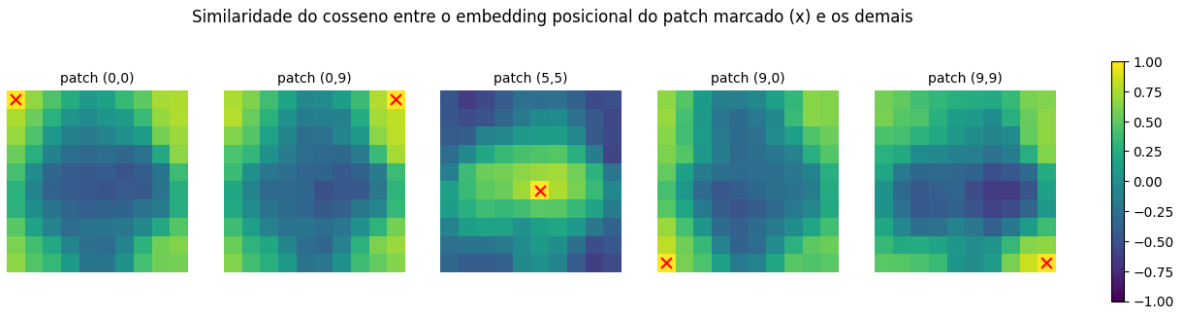
Atenção do `[CLS]` aos patches por cabeça e attention rollout no ViT do zero.

O que o ViT do zero aprende a ponderar. As três cabeças da mesma camada têm comportamentos distintos. Algumas (cabeça 0 em Heels e Backpacks) concentram a atenção em **poucas colunas**, ou seja, poucos tokens-chave recebem a atenção de quase todos os demais, funcionando como pontos de agregação global. Outras exibem um **padrão em grade**, típico de atenção entre grupos de patches parecidos. Nos mapas `[CLS]` → patches, a atenção é esparsa e específica por cabeça: em *Heels*, as cabeças 0 e 1 focam o cano e a fivela da sandália, regiões discriminativas; em *Tshirts*, uma cabeça olha o rosto, outra o braço e a barra da calça. Em *Watches* e *Backpacks* algumas cabeças se dispersam pelo fundo branco, de modo que uma única cabeça não carrega a decisão. O *rollout* consolida as camadas e destaca o corpo do produto (sandália, mochila, mostrador e pulseira); em *Tshirts* parte da energia cai sobre braços e pernas, mostrando que o modelo usa o contexto “modelo vestindo a peça”.



Atenção do ViT-B/16 pré-treinado: `[CLS]` → patches (última camada) e attention rollout.

ViT-B/16 pré-treinado. A atenção direta do `[CLS]` na última camada concentra-se em **patches de fundo e de borda**, com pouca atenção ao objeto. Esse comportamento é conhecido em ViTs grandes: tokens de fundo, pobres em informação local, passam a armazenar informação global e atraem atenção (tokens de alta norma). O *rollout*, ao contrário, destaca claramente a sandália, a mochila inteira e o relógio com a pulseira. Conclusão prática: a atenção bruta da última camada é um mau indicador do que o modelo usa, e o *rollout* é mais interpretável.



Similaridade do cosseno entre embeddings posicionais aprendidos do ViT do zero.

Embeddings posicionais. Inicializados aleatoriamente, os embeddings posicionais **adquiriram estrutura espacial**: cada patch é mais parecido com seus vizinhos do que com patches distantes, e a correlação entre distância espacial e similaridade posicional é negativa (−0,262). O patch central tem um halo circular de alta similaridade e os cantos se parecem entre si, coerente com a periferia branca das imagens. O modelo aprendeu a noção de grade 2D que a convolução já traz por construção.

1.5 Análise crítica

- **Pré-treino foi o fator decisivo:** +10,75 pontos percentuais do ViT-B/16 sobre o ViT do zero, com convergência em 1 a 4 épocas (91,4% de validação já na primeira) contra 60 épocas. O ViT do zero tem poucos dados e nenhum viés de localidade.
- **ViT-B/16 contra ResNet-18:** diferença de 1,58 p.p., com intervalos de confiança que se sobrepõem (93,50 a 95,26% contra 91,82 a 93,78%), logo sem evidência firme de que o ViT-B/16 seja melhor. O custo é muito diferente: 85,8 M contra 11,2 M de parâmetros, ~9× mais tempo de treino e inferência ~21× mais lenta. Para este problema, a ResNet-18 entrega quase a mesma qualidade por uma fração do custo.
- **ViT do zero:** não sobreajustou (acurácia de treino 87,2% contra 85,6% de validação; a perda de validação fica abaixo da de treino porque dropout, *drop path*, *label smoothing* e augmentation só atuam no treino) e ainda melhorava ao final, ou seja, está **subajustado**. Mais épocas, mais dados ou pré-treino auto-supervisionado (MAE, DINO) reduziriam a distância. A ResNet-18, ao contrário, mostra folga de ~4 p.p. entre treino (97,4%) e validação (93,3%).
- **Erros** concentram-se em pares de categorias vizinhas dentro da mesma família (calçados, camisetas), cuja fronteira é semântica (uso, ocasião) e não visual, além de ruído de rotulagem do catálogo. Em varejo isso é menos grave que trocar famílias de produto.
- **O que mudaria:** resolução maior (as imagens têm ~60×80 px), metadados do catálogo (gênero, subcategoria) como entrada complementar, mais épocas para o ViT do zero, múltiplas sementes para estimar variância e um backbone híbrido ou DeiT/Swin se o objetivo fosse treinar do zero com poucos dados.
- **Limitações:** uma única divisão e uma única semente; imagens de baixa resolução; 20 classes com no máximo 1.000 imagens; o tempo de treino compara configurações com resolução e épocas diferentes na T4.

Pré-treino do BERT e do ViT, DeiT e Swin

O **BERT** é pré-treinado de forma auto-supervisionada, prevendo tokens mascarados com contexto bidirecional (e a próxima sentença), sem rótulos humanos, sobre um vocabulário discreto finito. O **ViT original** é pré-treinado de forma **supervisionada** (ImageNet-21k ou JFT-300M); variantes recentes (MAE, DINO, BEiT) usam objetivos auto-supervisionados análogos ao do BERT, como reconstruir patches mascarados. Em imagens, os pixels vizinhos são muito redundantes, então é preciso mascarar proporções grandes (≈75% no MAE), e não existe um vocabulário natural a prever. Sem o viés indutivo das CNNs, o ViT depende muito mais do volume de dados no pré-treino, o que o experimento A1 confirma.

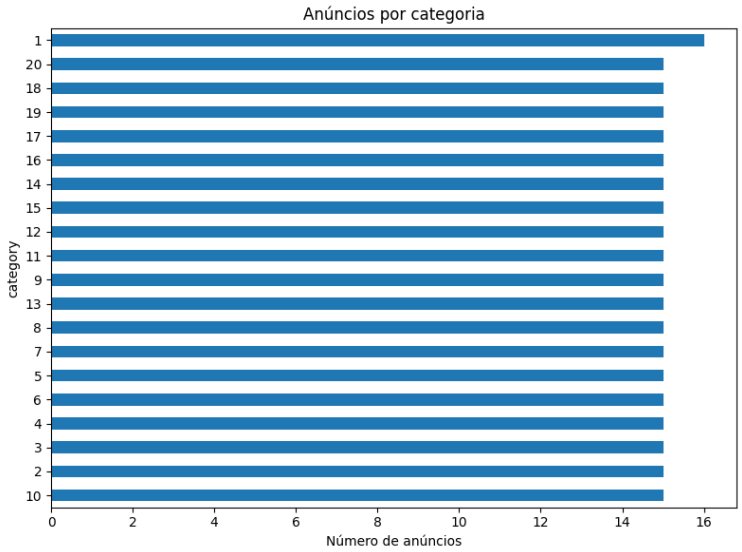
Aspecto	**ViT**	**DeiT**	**Swin**
Dados de pré-treino	ImageNet-21k / JFT-300M	Apenas ImageNet-1k	ImageNet-1k ou 21k
Ideia central	Patches 16×16 com atenção global	Receita eficiente em dados (RandAugment, Mixup, CutMix, destilação)	Atenção em janelas locais deslocadas e representação hierárquica
Token extra	`[CLS]`	`[CLS]` + token de destilação (professor CNN)	Sem `[CLS]`; pooling global médio
Complexidade	Quadrática no nº de patches	Quadrática	Linear no tamanho da imagem
Saída	Mapa único	Idem ao ViT	Mapas multi-escala (detecção, segmentação)

Atividade 2: Reconhecimento semântico em publicidade visual com CLIP

2.1 Definição do problema

Extrair inteligência semântica de um corpus de anúncios **sem treinar nenhum modelo**: apenas embeddings pré-treinados do CLIP (`openai/clip-vit-base-patch32`) e consultas em linguagem natural. A atividade tem duas partes: (2.1) ranquear os objetos mais frequentes no corpus por similaridade de cosseno com descrições textuais e (2.2) implementar busca de imagens por texto.

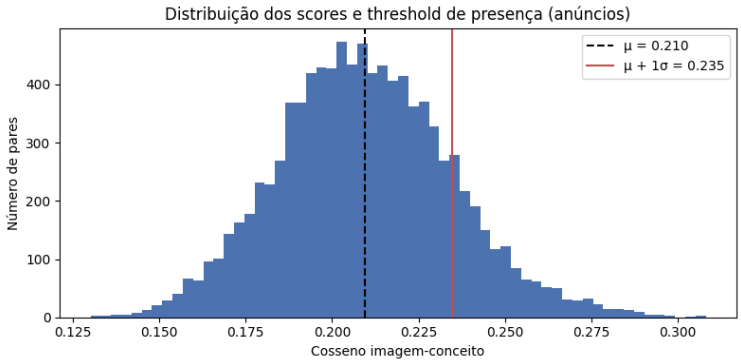
Corpus. O ADS-16 (Roffo e Vinciarelli, 2016) documenta 300 anúncios em 20 categorias de produto (o enunciado menciona 16) e cerca de 1.200 fotos pessoais de usuários. Após remover duplicatas por hash MD5, restaram **301 anúncios únicos** e **1.200 fotos pessoais únicas**. Como o dataset tem menos de 500 anúncios, foram usados dois corpora: o **principal** (301 anúncios), para a busca e o ranking principal, e o **estendido** (1.501 imagens: anúncios mais fotos pessoais), que atende ao mínimo de 500 imagens no ranking e permite contrastar publicidade com fotos do cotidiano.



Anúncios por categoria (as categorias são identificadas apenas por números).

2.2 Decisões técnicas

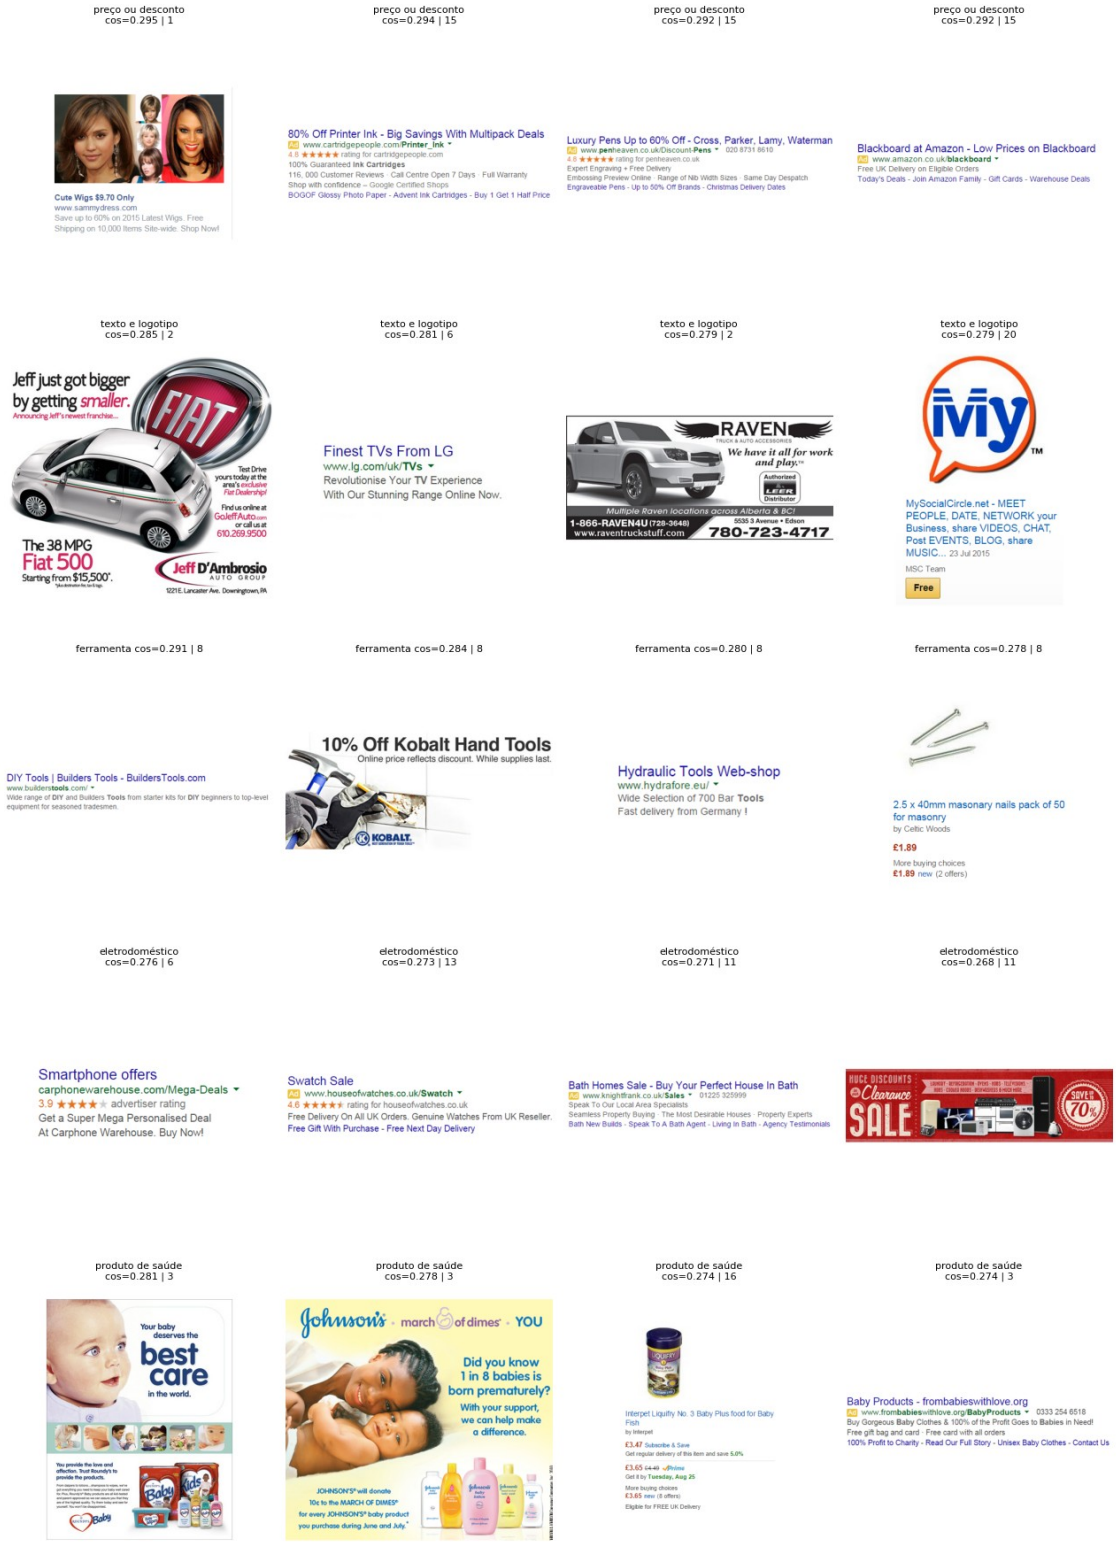
- **CLIP ViT-B/32** (151,3 M de parâmetros), com duas torres (imagem e texto) projetadas para 512 dimensões; embeddings normalizados, de modo que o produto escalar é o cosseno.
- **Pré-processamento:** o `CLIPProcessor` redimensiona e recorta o centro; os embeddings das imagens foram calculados uma única vez (1.501 imagens em 393,7 s em CPU) e reutilizados em todas as consultas.
- **32 conceitos** (pessoas, produtos de consumo, cenários e elementos gráficos), cada um codificado com um **ensemble de três templates** de prompt (“an advertisement showing {c}”, “a photo of {c}”, “an image containing {c}”), cujo vetor médio normalizado representa o conceito. O ensemble reduz a dependência de uma redação específica.
- **Threshold de presença relativo, μ + 1σ (= 0,235).** Os cossenos do CLIP ficam numa faixa estreita (≈0,1 a 0,35) por causa do *modality gap*, então um corte absoluto (como 0,5) não faz sentido. μ e σ (0,2096 e 0,0252) são calculados sobre todos os pares (imagem, conceito) do corpus principal e o mesmo corte é aplicado aos demais corpora. A justificativa é que um anúncio mostra poucos dos 32 conceitos, então a maioria dos pares é “ausente” e forma o corpo da distribuição; um score um desvio padrão acima dele é estatisticamente saliente.



Distribuição dos cossenos imagem-conceito e threshold μ + 1σ.

2.3 Resultados da atividade 2.1: ranking de objetos

#	Objeto	Frequência	Anúncios	Score médio	Score quando presente
1	preço ou desconto	78,1%	235	0,251	0,259
2	texto e logotipo	51,8%	156	0,233	0,250
3	ferramenta	37,9%	114	0,228	0,247
4	eletrodoméstico	33,6%	101	0,224	0,247
5	produto de saúde	31,9%	96	0,224	0,249
6	brinquedo	29,2%	88	0,225	0,247
7	videogame	28,6%	86	0,222	0,249



Os cinco objetos mais frequentes, com os quatro anúncios de maior score para cada um (cada

linha é um objeto: preço ou desconto, texto e logotipo, ferramenta, eletrodoméstico, produto de saúde).

Confirmação visual. Os exemplos confirmam *preço ou desconto* (“up to 60% off”, “80% off”, “low prices”), *texto e logotipo* (Fiat 500, LG, Raven) e *ferramenta* (Kobalt, builders tools, hydraulic tools, pregos; todos da categoria 8). *Eletrodoméstico* tem um desvio: três dos quatro exemplos são anúncios apenas de texto (“Smartphone offers”, “Swatch Sale”), e só o último mostra eletrodomésticos. O CLIP reage ao **estilo do anúncio** (texto de promoção) tanto quanto ao objeto citado. *Produto de saúde* captura sobretudo produtos de bebê e cuidado infantil (categoria 3), uma aproximação semântica razoável, não literal.

Corpus estendido. Com as fotos pessoais, *pessoa* sobe para o 3º lugar (18,7%) e *animal de estimação* entra no top 8 (13,2%), enquanto *preço ou desconto* cai para 22,7%: o ranking reflete o corpus. Anúncios giram em torno de produto e texto; fotos pessoais, em torno de pessoas e animais.

Sensibilidade ao threshold.

Regra de presença	**Objetos do top 5 em comum com a regra principal**	**Objetos detectados por imagem**
μ + 0,5σ	4	9,60
μ + 1σ (regra principal)	5	4,93
μ + 1,5σ	5	2,22
top-3 conceitos por imagem	3	3,00

O ranking é estável em torno do threshold escolhido, e os dois primeiros colocados não dependem da regra.

2.4 Resultados da atividade 2.2: busca semântica

A busca codifica a consulta, calcula o cosseno contra todos os vetores do corpus principal e devolve as 5 imagens mais similares. Foram executadas **10 consultas** de especificidade variável. O *z-score* do 1º colocado mede quantos desvios padrão ele está acima da média de scores da consulta no corpus.

#	**Consulta**	**Tipo**	**Cos. 1º**	**z-score**	**Resultado**
1	a person	genérica	0,230	3,00	Sites de encontros, atleta, modelo (lê o texto)
2	food	genérica	0,261	3,71	Ração, pizza, vegetais, snacks (correto)
3	a woman smiling while	específica	0,248	3,15	Capta o smartphone, não a cena

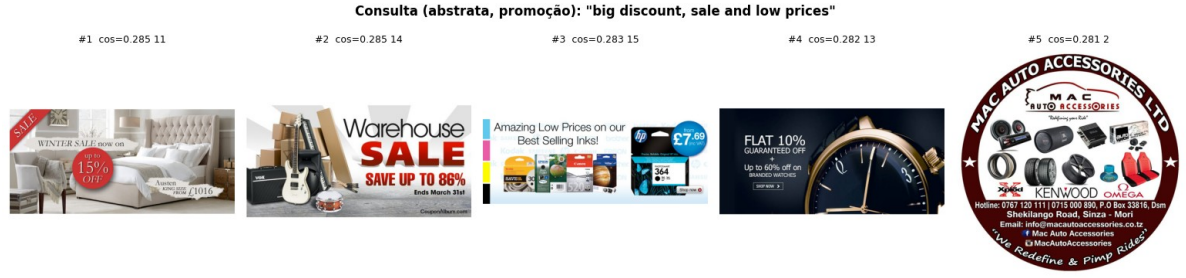
#	Consulta	Tipo	Cos. 1º	z-score	Resultado
	holding a smartphone				
4	a red sports car driving on a road	específica	0,230	3,04	Pandeireta vermelha e autopeças
5	a dog playing outdoors	específica	0,226	3,76	Pet shop, Pedigree; **hot dog** em 4º
6	a book cover with a title	formato	0,255	2,40	Falha: sela, sementes, mochila
7	text only advertisement without photographs	layout	0,293	1,99	5 de 5 anúncios só de texto
8	big discount, sale and low prices	abstrata	0,285	2,61	4 de 5 banners de liquidação
9	luxury and elegance	abstrata	0,223	2,67	Joias, canetas, Gucci, TV cara
10	happiness and family time	abstrata	0,224	3,43	Mãe e bebê, casal; erros: ferramentas, Lego



Busca "a woman smiling while holding a smartphone": top 5.



Busca "a dog playing outdoors": o anúncio de hot dog aparece em 4º por ambiguidade lexical.



Busca "big discount, sale and low prices": 4 de 5 resultados são banners de liquidação.



Busca "happiness and family time".

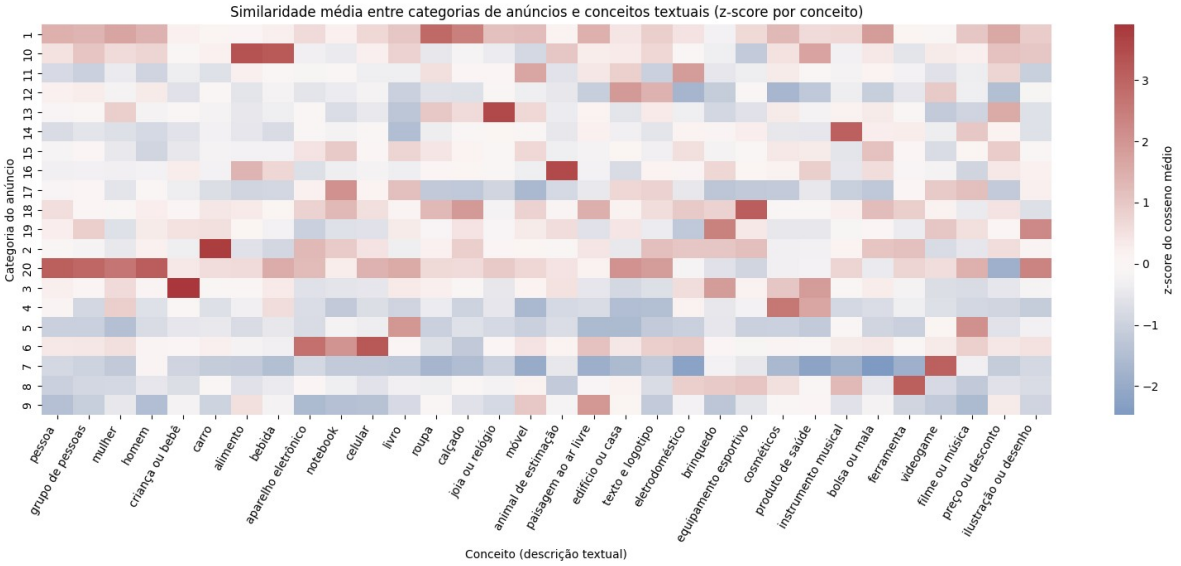
Interpretação por tipo de consulta.

- **Concretas e genéricas (1, 2):** funcionam quando o conceito é um tema forte do corpus (comida). "A person" é interpretado de forma inesperada: o CLIP lê o texto "Meet New People", "Dating Site" e associa pessoa a encontros.
- **Concretas e específicas (3, 4, 5):** as combinações de atributos são recuperadas **por partes**: o modelo acerta o substantivo dominante e perde a relação entre os atributos e a cena. Como o corpus não contém essas cenas, devolve o mais próximo (pandeireta vermelha, autopeças) com cosseno e z-score parecidos com os de buscas bem-sucedidas: **um score alto não indica que o conteúdo existe**. A confusão com *hot dog* mostra o viés lexical herdado dos pares imagem-texto da web.
- **Formato e layout (6, 7):** "anúncio apenas de texto" funciona porque o CLIP reconhece o estilo visual do anúncio de busca patrocinada; "capa de livro" falha porque o corpus não tem capas. O z-score da consulta 7 é o menor (1,99) mesmo com o melhor resultado, porque muitos anúncios de texto compartilham scores altos e elevam o desvio padrão. Logo, o z-score mede quão **isolado** é o melhor resultado, não a qualidade da busca.
- **Abstratas (8, 9, 10):** "sale", "luxury" e "family" não têm objeto físico, e mesmo assim o modelo recupera banners de liquidação, marcas de luxo e cenas materno-infantis. O vocabulário aberto do pré-treino contrastivo captura conceitos associados a contextos visuais e textuais recorrentes. O ponto fraco é o ruído nas posições inferiores.

2.5 Análise do alinhamento visual-textual

Por que o CLIP permite busca sem treino. O CLIP foi treinado com ~400 milhões de pares imagem-texto. Em cada lote de N pares forma-se uma matriz N×N de similaridades e uma entropia cruzada simétrica faz cada imagem preferir seu texto (diagonal) em relação aos outros N−1 textos, e vice-versa; os pares incorretos do lote servem de negativos, sem rótulos manuais. Isso cria um espaço compartilhado de 512 dimensões onde proximidade é relação semântica, e um vocabulário aberto: uma descrição nova pode ser codificada na hora e comparada às imagens.

Zero-shot por categoria. A acurácia top-1 foi de **4,3%** (acaso: 5,0%) e o cosseno médio com a categoria correta (0,2243) é igual ao das demais. Isso **não indica falha do CLIP**: as 20 categorias do dataset são identificadas apenas por números, e o prompt "an advertisement for 7" não tem conteúdo semântico. O experimento mostra que a classificação zero-shot depende de nomes de classe significativos.



Mapa de calor: similaridade média entre cada categoria de anúncio e os conceitos textuais (z-score por conceito).

O mapa de calor mostra que, apesar disso, **o CLIP separa as categorias**: cada categoria numérica tem um perfil semântico próprio, coerente com as buscas (categoria 2: carro; 3: criança ou bebê; 8: ferramenta; 10: alimento e bebida; 13: joia ou relógio; 16: animal de estimação; 20: pessoas). Nomear cada categoria pelo seu conceito dominante tornaria o zero-shot viável.

Geometria do espaço. O cosseno médio é 0,48 entre imagens, 0,86 entre textos e 0,21 entre imagem e texto: os textos ficam muito mais próximos entre si do que as imagens, e o par cross-modal é baixo. É o *modality gap*, que explica os cossenos baixos (≈0,2 a 0,3) mesmo em boas correspondências e a escolha de um threshold relativo.

CLIP e BERT. Sem `attention_mask`, o vetor `[CLS]` do BERT muda quando há padding (cosseno de 0,627 em relação à frase sem padding), porque a atenção é bidirecional e o padding contamina todos os tokens. No CLIP o resultado foi idêntico (1,000) com ou sem máscara, porque a atenção é causal e o vetor vem do token `<|endoftext|>`, que não enxerga o padding posterior.

Aspecto	**CLIP (texto)**	**BERT**
Tokenizador	BPE em nível de byte	WordPiece (`bert-base-uncased`)
Tokens especiais	`<|startoftext|>`, `<|endoftext|>`	`[CLS]`, `[SEP]`
Contexto máximo	77 tokens	512 tokens
Atenção	causal	bidirecional
Vetor usado	estado em `<|endoftext|>`, projetado a 512	`[CLS]` ou todos os tokens
Pré-treino	contrastivo imagem-texto	MLM e NSP

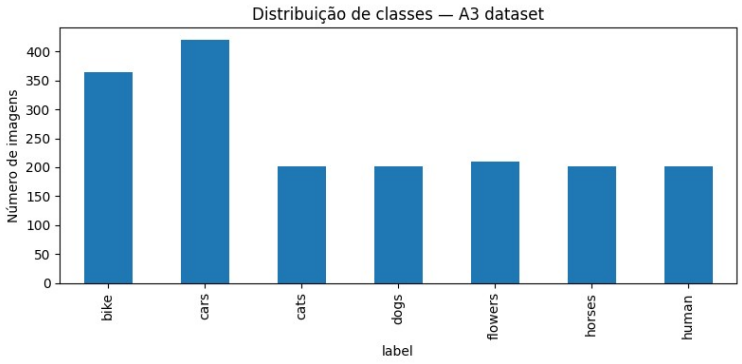
2.6 Análise crítica

- O CLIP ranqueou objetos e buscou imagens por linguagem natural **sem treino**, com bons resultados em temas fortes do corpus (promoção, comida, luxo, texto) e fracos em composições específicas e em conceitos ausentes. Das 10 consultas, 5 foram majoritariamente corretas (2, 7, 8, 9, 10), 4 parciais (1, 3, 4, 5) e 1 falhou (6).
- Riscos: o modelo combina conceitos de forma superficial, depende do **texto embutido** nas imagens (muito presente em anúncios), sempre devolve algo mesmo quando o conteúdo não existe e herda vieses da web. Um score alto, isoladamente, não prova a presença do objeto.
- Limitações: o resultado depende da lista de 32 conceitos, do threshold e dos templates; não há rótulos de referência para os objetos, então a avaliação é qualitativa; o corpus principal tem só 301 anúncios (o mínimo de 500 imagens foi atendido pelo corpus estendido); o notebook foi executado em CPU (indexação de 393,7 s), e em GPU T4 essa etapa é mais rápida.
- O que mudaria: um conjunto pequeno de imagens anotadas para medir precisão@5 das buscas; calibrar o threshold por conceito; reescrever as categorias com nomes reais para o zero-shot; e comparar CLIP ViT-B/16 e ViT-L/14.

Atividade 3: Classificador com CNN pré-treinada

3.1 Definição do problema

Construir um classificador supervisionado por **transfer learning por feature extraction**: carregar uma CNN pré-treinada, congelar o backbone, substituir a cabeça de classificação e treinar apenas a nova camada. O dataset (*Images Dataset*, Kaggle) tem **1.803 imagens em 7 categorias**: bike, cars, cats, dogs, flowers, horses e human. O desbalanceamento é moderado (cars: 420 imagens, 23,3%; bike: 365, 20,2%; as outras cinco classes entre 202 e 210), com razão de ~2,1:1 entre a maior e a menor classe. Por isso não foram usados pesos de classe, e as métricas são reportadas por classe e em média macro.



Distribuição das imagens por categoria.

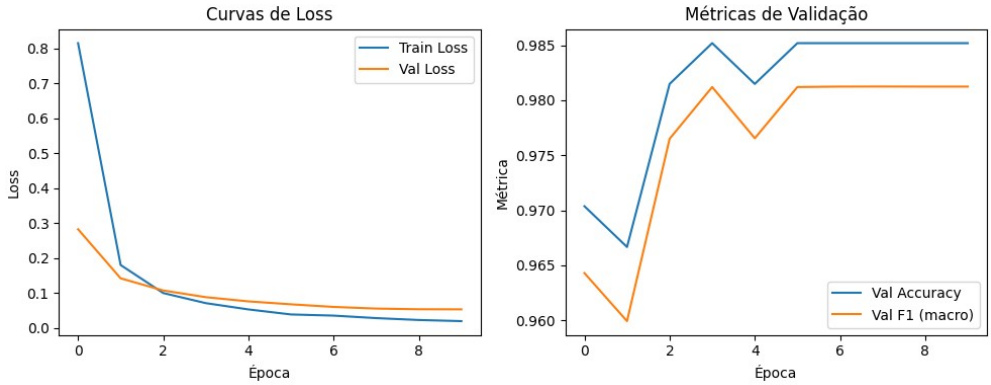


Amostras de cada categoria.

3.2 Decisões técnicas

- **ResNet-50** (pesos `IMAGENET1K_V2`, 23,5 M de parâmetros): o dataset é pequeno e tem classes genéricas próximas ao conteúdo do ImageNet, então as features pré-treinadas são diretamente aproveitáveis. A EfficientNet-B0 também seria suficiente; a ResNet-50 foi escolhida por produzir uma representação maior (2.048 valores) sem custo proibitivo na T4, e por ser estável e bem estabelecida para extração de features. Uma rede maior (ResNet-101) não se justificaria.
- **Backbone congelado e nova cabeça** `Linear(2048 → 7)`**:** apenas **14.343 parâmetros treináveis (0,06% do total)**.
- **Normalização com a média e o desvio do ImageNet** (`[0,485; 0,456; 0,406]` e `[0,229; 0,224; 0,225]`), obrigatória porque os pesos esperam essa distribuição de entrada; *resize* para 224×224.
- **Divisão estratificada 70/15/15:** 1.262 imagens de treino, 270 de validação e 271 de teste.
- **Treino:** Adam (LR 1e-3), perda de entropia cruzada, batch 32, 10 épocas; o *checkpoint* é o da menor perda de validação.

3.3 Resultados

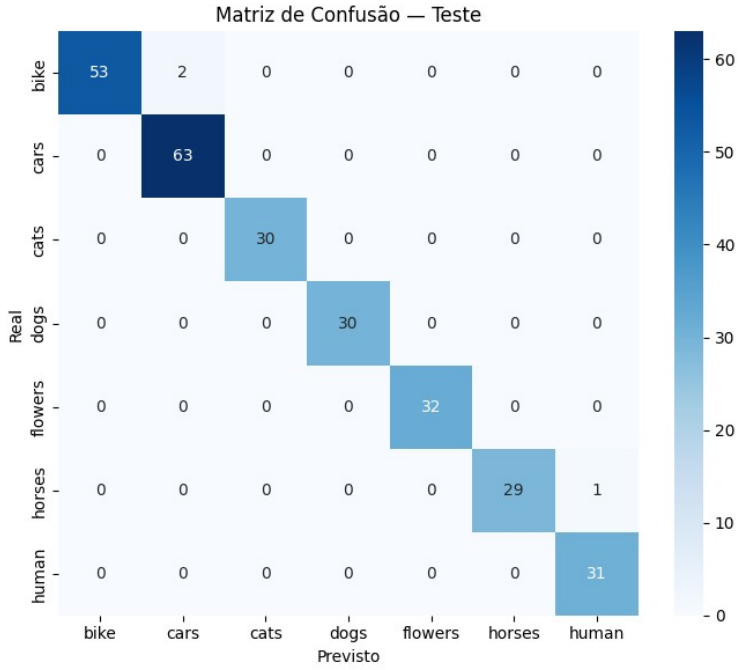


Curvas de perda e acurácia por época (treino e validação).

A acurácia de validação já era 0,9704 na época 1 (as features do ImageNet são diretamente aproveitáveis) e chegou a 0,9852 (266 de 270) na época 4, mantendo-se até a 10. A perda de validação caiu de forma monotônica de 0,2822 para 0,0530, com ganhos marginais nas últimas épocas (convergência). A diferença entre perda de validação e de treino permanece pequena, sem a inversão típica de overfitting, o que é esperado com apenas 0,06% dos parâmetros treináveis.

Resultado no teste: acurácia global **98,89%** (268 de 271), F1 macro 0,9904, perda 0,0445, consistente com a validação (98,52%), o que indica que a seleção do checkpoint não superajustou a validação.

Classe	Acurácia (recall)	Suporte
bike	0,9636 (53/55)	55
cars	1,0000 (63/63)	63
cats	1,0000 (30/30)	30
dogs	1,0000 (30/30)	30
flowers	1,0000 (32/32)	32
horses	0,9667 (29/30)	30
human	1,0000 (31/31)	31
global	**0,9889 (268/271)**	271



Matriz de confusão no conjunto de teste.



Os três erros do conjunto de teste.

Análise dos erros (3 em 271). (1) *bike → cars* (pátio residencial): as bicicletas aparecem pequenas, empilhadas e cortadas na borda, e a cena é dominada por uma fachada e um telhado; (2) *horses → human*: a imagem é uma **ilustração em estilo low-poly**, e não uma fotografia; (3) *bike → cars* (garagem): a bicicleta é pequena e está parcialmente tapada por uma cancela. As hipóteses, não verificadas com Grad-CAM, são escala pequena do objeto, oclusão e contexto associado a carros (cars também é a maior classe, 23%), e mudança de domínio visual no caso da ilustração. O erro parece vir de escala, oclusão e domínio, e não de semelhança entre classes.

3.4 Análise crítica e propostas de melhoria

Com 3 erros em 271 imagens o resultado está próximo do teto, e cada imagem vale 0,37 p.p. de acurácia global, de modo que o teste é pouco informativo para comparar melhorias pequenas. O dataset também é relativamente fácil: as classes são bem representadas no ImageNet.

Feature extraction ou fine-tuning. Feature extraction é adequada aqui: dataset pequeno e domínio próximo do ImageNet, com baixo risco de overfitting. O fine-tuning (descongelar as últimas camadas, com LR bem menor no backbone) seria preferível se o domínio divergisse, como em radiografias (atividade 4.1), e se tornaria mais seguro com mais dados. Aqui traria ganho marginal ao custo de mais risco de overfitting.

Augmentations consideradas e riscos por classe.

Técnica	**Benéfica?**	**Risco ou classe afetada**
Flip horizontal	Sim, para as 7 classes	Nenhuma tem orientação esquerda/direita fixa
Flip vertical	Não recomendado	Carros, bicicletas, cavalos, cães, gatos e pessoas de cabeça para baixo não ocorrem na distribuição real
Rotação leve (±10 a 15°)	Sim, robustez a fotos inclinadas	Acima de ~30° gera cenas irreais (horizonte inclinado, carros tombados)
Recorte aleatório	Útil para robustez a enquadramento	Em *flowers* pode remover a flor e deixar só folhagem; em *bike*, onde o objeto é pequeno, pode eliminar a bicicleta (justamente o tipo de

Técnica	Benéfica?	Risco ou classe afetada
		erro observado)
Color jitter	Útil para variações de iluminação	Pode distorcer a cor em *flowers*, onde a cor é uma pista discriminativa; manter leve
Conversão aleatória para grayscale	Com cautela	Remove a cor, que ajuda a distinguir *flowers* de fundos verdes; uso ocasional ($p \approx 0{,}1$)
Resize aleatório com crop / multi-scale	Sim, para os erros de escala observados (bike)	Reduções fortes tornam objetos pequenos irreconhecíveis
Normalização com média e desvio do ImageNet	**Obrigatória** (já aplicada)	Estatísticas diferentes desalinham a entrada dos pesos pré-treinados

A ordem de testes que eu seguiria: (i) recorte com escala e *multi-scale*, que ataca diretamente os erros de *bike*; (ii) flip horizontal e rotação leve; (iii) color jitter leve; e, só depois, (iv) fine-tuning da última camada convolucional com LR baixo. Como o teste tem apenas 271 imagens, as comparações precisariam de várias sementes ou validação cruzada para distinguir melhoria real de variação.

Atividade 4.1: Detecção de COVID-19 em radiografias de tórax

4.1.1 Definição do problema

Um grupo desenvolveu um sistema de triagem de pneumonia e COVID-19 com 1.200 radiografias (Normal: 840, Pneumonia: 240, COVID-19: 120), divisão 80/20 sem estratificação, **ResNet-18 sem pré-treinamento**, SGD com *learning rate* fixo de 0,01, 15 épocas, sem augmentation e avaliação apenas por acurácia global (93% de treino e 61% de validação). O time clínico relatou que o modelo “ignora casos positivos”. O objetivo é diagnosticar o projeto (ao menos cinco problemas), implementar uma abordagem generativa para a escassez da classe COVID-19, medir o impacto no *recall* da classe minoritária e propor um plano integrado. Nour e Tariq (2023) documentam o mesmo padrão: acurácia global alta e recall de COVID-19 abaixo de 60% em bases desbalanceadas.

4.1.2 Diagnóstico: problemas técnicos e impacto clínico

#	Problema	Evidência no caso	Impacto clínico esperado
1	**Desbalanceamento não tratado** (70% / 20% / 10%)	A perda é dominada por Normal; COVID tem 120 exemplos	O modelo favorece Normal e **deixa de detectar COVID**: falsos negativos, pacientes infectados liberados sem isolamento
2	**Métrica inadequada** (somente acurácia global)	Prever sempre “Normal” daria 70%; os 61% de validação ficam abaixo	O número reportado esconde a falha na classe crítica; a decisão de implantar se apoia em uma métrica que não mede o

#	Problema	Evidência no caso	Impacto clínico esperado
		desse baseline trivial se a validação mantiver a proporção	risco clínico (faltam recall por classe, F1 macro, matriz de confusão)
3	**Divisão 80/20 sem estratificação e sem teste independente**	20% de 120 COVID ≈ 24 casos, com proporção variável; a "validação" é o resultado final	Estimativa de recall instável e otimista, sem intervalo de confiança; risco de vazamento entre imagens do mesmo paciente
4	**Sem pré-treinamento** (~11 M de parâmetros, 1.200 imagens)	93% de treino contra 61% de validação	**Overfitting**: o modelo decora o treino e não generaliza para novos pacientes
5	**Sem augmentation**	As mesmas 1.200 imagens em todas as épocas	Memorização e fragilidade a variações de posicionamento, contraste e equipamento entre hospitais
6	**Otimização pobre** (SGD, LR fixo, 15 épocas, sem checkpoint nem early stopping)	Sem *scheduler* nem seleção do melhor modelo	O modelo final é o da última época, possivelmente instável; resultados irreproduzíveis
7	**Risco de atalhos espúrios** (*shortcut learning*)	Em bases de COVID as classes frequentemente vêm de fontes e equipamentos distintos	O modelo pode aprender a fonte da imagem (marcas, letras, contraste) e não a patologia, e falhar em outro hospital

Os problemas 1, 4 e 5 podem ser tratados com dados (augmentation e imagens sintéticas), o 4 e o 6 com o pipeline de treino, e o 2, o 3 e o 7 com a metodologia de avaliação.

4.1.3 Decisões técnicas

Abordagem generativa escolhida: GAN condicional (cGAN, estilo DCGAN), que recebe o rótulo da classe como condição e gera radiografias sintéticas de COVID-19. A escolha de uma cGAN, em vez de CycleGAN, deve-se ao fato de o problema ser de **escassez de uma classe** em um único domínio (não de tradução entre domínios pareados ou não pareados), e de a cGAN permitir controlar a classe gerada. Como cada passo de treino da GAN depende de poucos dados (120 imagens de COVID-19), foram adotadas medidas de estabilidade:

1. **Amostragem balanceada por classe** em cada passo, para o gerador ver COVID-19 com a mesma frequência que Normal;
2. **Normalização espectral** no discriminador (limita a constante de Lipschitz e impede que ele domine);
3. ***Differentiable augmentation*** (brilho e translação aleatórios, aplicados às imagens reais e às geradas antes do discriminador), que reduz o overfitting do discriminador em dados pequenos;
4. **Rótulo suavizado** (0,9 para imagens reais) e Adam com $\beta 1 = 0{,}5$;
5. Monitoramento de D(real), D(falso) e das perdas e, depois, checagens de **memorização** e

diversidade (colapso de modo).

Dados e protocolo. O dataset é o *COVID-19 Radiography Database* (Kaggle), com as classes COVID, Normal e Viral Pneumonia (usada como "Pneumonia"). O **treino reproduz a composição do caso** (840, 240 e 120). Como 18 casos de COVID (15% de 120) seriam insuficientes para medir recall, a avaliação usa conjuntos **disjuntos, estratificados e balanceados**: validação com 60 imagens por classe (seleção de *checkpoint*) e **teste com 300 imagens por classe**, todos reais. As imagens são em tons de cinza, 64×64 (resolução da GAN).

Arquitetura. O gerador recebe ruído de 100 dimensões e um embedding do rótulo, projeta para 4×4×512 e aplica quatro `ConvTranspose2d` (BatchNorm e ReLU) até 64×64 com saída `tanh`. O discriminador recebe a imagem concatenada ao rótulo (one-hot em canais) e aplica quatro convoluções com *stride* 2, normalização espectral e LeakyReLU, terminando em um logit. Treino de 6.000 passos, batch 64, Adam (LR 2e-4).

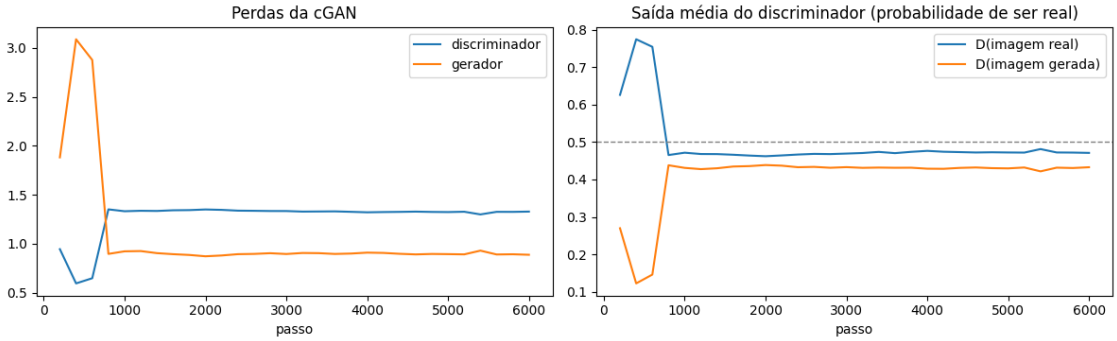
Classificador e configurações comparadas. ResNet-18 em quatro configurações, cada uma treinada com 3 sementes e avaliada no teste real:

Configuração	**Pré-treino**	**Otimização**	**Augmentation**	**Pesos de classe**	**COVID sintético**
1. Caso original	não	SGD (momentum 0,9), LR 0,01 fixo, 15 épocas, última época	não	não	não
2. Melhorado, sem sintéticas	ImageNet	AdamW, LR 3e-4 (one-cycle), 20 épocas, melhor época na validação	sim	não	não
3. Melhorado + pesos de classe	ImageNet	idem	sim	sim	não
4. Melhorado + GAN	ImageNet	idem	sim	não	+480 (120 reais + 480 sintéticas)

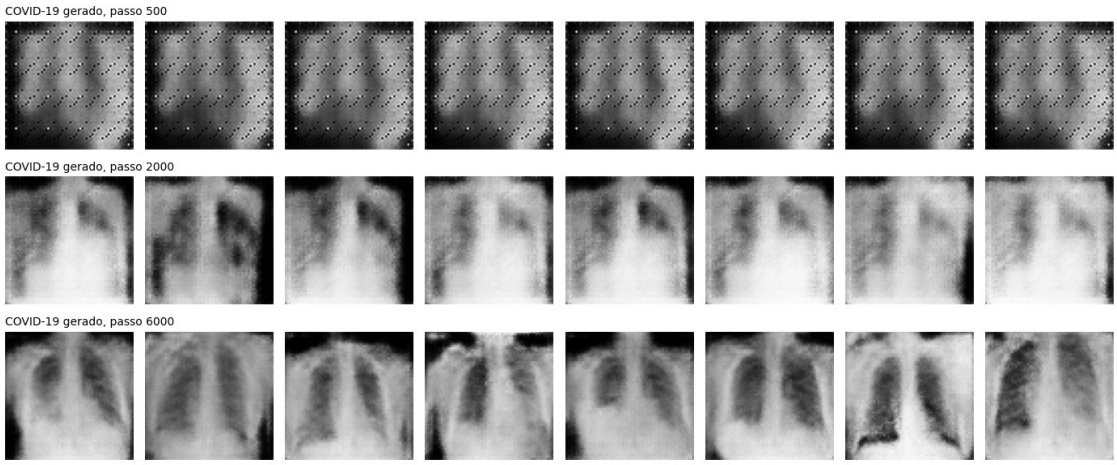
A augmentation do pipeline melhorado (rotação ±10°, zoom 0,9 a 1,1, deslocamento ±5%, brilho e contraste) **não inclui espelhamento horizontal**, pois inverter uma radiografia posicionaria o coração à direita, uma anatomia rara. O momentum de 0,9 na configuração 1 é uma hipótese (o enunciado diz apenas "SGD"). As imagens sintéticas foram usadas **somente no treino**.

4.1.4 Resultados

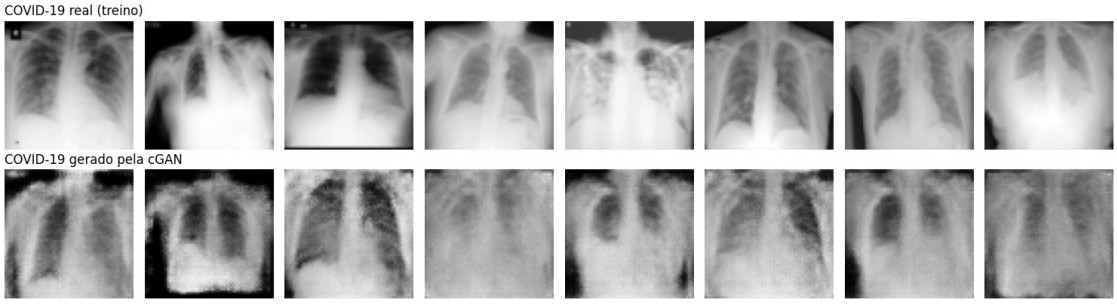
Treino da GAN. Em 6.000 passos (9,3 min na T4), as perdas ficaram estáveis (discriminador ≈ 1,33; gerador ≈ 0,89) e a saída média do discriminador permaneceu perto de 0,5 (D(real) ≈ 0,47 e D(falso) ≈ 0,43), sem colapso nem divergência. A evolução das amostras mostra o treino funcionando: no passo 500 o gerador produz o mesmo padrão ruidoso para qualquer entrada; no passo 2.000 já aparecem tórax e pulmões, ainda pouco variados; no passo final há diversidade de formato pulmonar, contraste e posição.



Perdas da cGAN e saída média do discriminador por passo.



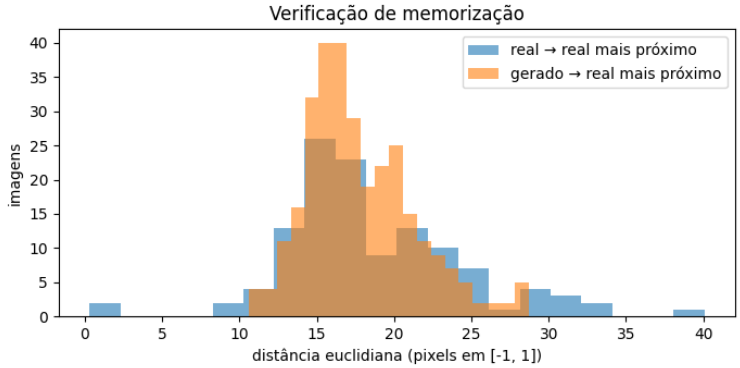
COVID-19 gerado (mesmo ruído nos três instantes) nos passos 500, 2.000 e 6.000.



Linha superior: radiografias reais de COVID-19 (treino). Linha inferior: imagens geradas pela

cGAN.

Memorização e diversidade. A distância ao vizinho mais próximo do treino real é de 17,81 para as imagens geradas e 18,64 entre as próprias imagens reais, ou seja, as geradas **não são cópias** do treino (se fossem, a distância seria muito menor). A distância média entre pares é de 28,64 nas geradas contra 34,07 nas reais: a diversidade gerada é ~84% da real, uma perda moderada, sem colapso de modo. Visualmente, as imagens geradas têm textura mais granulada e contornos mais suaves que as reais.

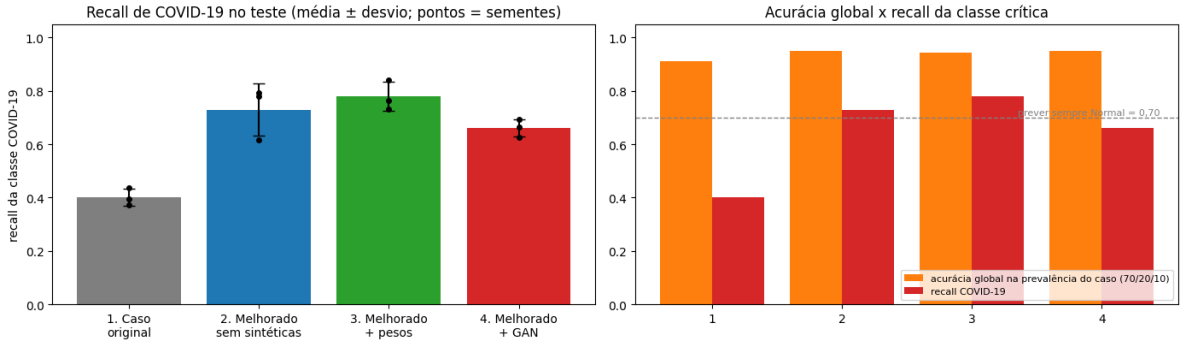


Verificação de memorização (distância ao vizinho mais próximo).

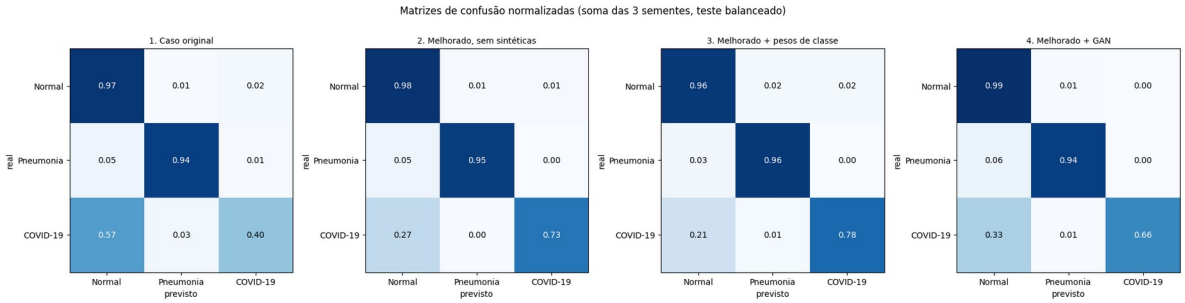
Classificação no teste real (300 imagens por classe), média ± desvio de 3 sementes.

Configuração	Recall COVID-19	Recall Pneumonia	Recall Normal	Precisão COVID-19	F1 macro	Acurácia balanceada	Acurácia na prevalência do caso (70/20/10)
1. Caso original	0,401 ± 0,032	0,940 ± 0,012	0,974 ± 0,002	0,935 ± 0,013	0,755 ± 0,017	0,772 ± 0,014	0,910 ± 0,005
2. Melhorado, sem sintéticas	0,730 ± 0,098	0,947 ± 0,010	0,981 ± 0,010	0,983 ± 0,007	0,885 ± 0,032	0,886 ± 0,030	0,949 ± 0,006
3. Melhorado + pesos de classe	**0,779 ± 0,055**	0,964 ± 0,020	0,963 ± 0,038	0,978 ± 0,024	**0,902 ± 0,022**	**0,902 ± 0,021**	0,945 ± 0,024
4. Melhorado + GAN	0,661 ± 0,033	0,940 ± 0,020	0,992 ± 0,005	0,997 ± 0,003	0,863 ± 0,009	0,864 ± 0,008	0,949 ± 0,004

Semente	1. Caso original	2. Melhorado	3. + pesos	4. + GAN
0	0,393	0,793	0,763	0,627
1	0,437	0,780	0,733	0,693
2	0,373	0,617	0,840	0,663



Recall de COVID-19 por configuração (barras: média; pontos: sementes) e acurácia global na prevalência do caso contra recall de COVID-19.



Matrizes de confusão normalizadas (soma das 3 sementes).

4.1.5 Análise crítica

O caso original reproduz o relato clínico. O modelo do caso, avaliado em um teste real e balanceado, detecta apenas **40,1% dos casos de COVID-19** (57% dos COVID viram “Normal”), enquanto a acurácia ponderada pela prevalência do caso (70/20/10) chega a **91,0%**. É a armadilha da acurácia global: um número alto convive com mais da metade dos positivos perdidos. Isso confirma o diagnóstico dos problemas 1 e 2 e é coerente com o recall abaixo de 60% descrito por Nour e Tariq (2023).

O pipeline melhorado resolve a maior parte do problema. Pré-treino, augmentation, AdamW com *one-cycle* e seleção do melhor checkpoint elevam o recall de COVID-19 de 40,1% para 73,0% (+32,9 p.p.) e o F1 macro de 0,755 para 0,885. Isso aponta que os problemas 4, 5 e 6 (pré-treino, augmentation e otimização) respondem pela maior parte da melhoria, antes de qualquer GAN.

As imagens geradas NÃO melhoraram o recall neste experimento. Com +480 imagens sintéticas de COVID-19, o recall caiu de 73,0% para **66,1% (−6,9 p.p.)**, e ficou 11,8 p.p. abaixo da alternativa mais simples de pesos de classe (77,9%). O que melhorou foi a **precisão** de COVID-19 (0,997, com quase nenhum Normal ou Pneumonia classificado como COVID) e o recall de Normal (0,992): o modelo ficou mais conservador. Em triagem, onde o falso negativo é o erro mais grave, o resultado é desfavorável. Duas ressalvas de rigor: (i) a variação entre sementes é grande (o desvio do recall da configuração 2 é 0,098, de 0,617 a 0,793), então com 3

sementes a diferença de −6,9 p.p. **não é estatisticamente conclusiva**, embora as três sementes do GAN (0,627 a 0,693) fiquem abaixo da média de 0,730 do pipeline sem sintéticas e mostrem menor variância; (ii) 480 imagens sintéticas e 120 reais é uma proporção de 4:1, um possível excesso.

Hipóteses para o resultado (não verificadas).

1. **Uma GAN treinada com 120 imagens não cria informação nova:** ela reorganiza o que viu e não acrescenta variações de achados patológicos (opacidades, consolidações) além das já presentes nas reais. A diversidade gerada (84% da real) e a textura mais granulada indicam fidelidade imperfeita aos sinais clínicos sutis.
2. **Atalho por artefato do gerador:** as imagens geradas têm uma textura diferente da das reais. O classificador pode associar "textura de GAN" à classe COVID-19 e, ao receber uma radiografia real de COVID-19 (sem esse artefato), tendê-la a "Normal". Isso é consistente com o padrão observado (precisão altíssima e recall menor), mas não foi testado (um teste direto seria medir quanto o classificador separa sintéticas de reais, ou treinar com sintéticas de fontes diferentes).
3. **Resolução limitada (64×64):** os sinais radiológicos de COVID-19 (opacidades difusas periféricas) são sutis e podem se perder nessa resolução, em imagens reais e sintéticas.
4. **Outras alternativas** de baixo custo, como os pesos de classe, atuam diretamente na perda sem introduzir artefatos e, aqui, funcionaram melhor.

Estabilidade e mitigação da GAN. O treino foi estável (sem colapso ou divergência) graças à amostragem balanceada, normalização espectral, *differentiable augmentation* e suavização de rótulos; não houve memorização. Mesmo assim, estabilidade de treino não implica utilidade clínica: o desempenho da GAN deve ser sempre julgado pelo efeito na tarefa final em dados reais.

4.1.6 Plano de melhoria integrado

#	Problema	Ação proposta	Métrica de verificação	Evidência neste trabalho
1	Desbalanceamento	**Pesos de classe na perda** (melhor resultado: recall 0,779), amostragem balanceada, coleta de mais casos reais de COVID-19; usar imagens sintéticas apenas se validadas em dados reais e em menor proporção	Recall de COVID-19 e matriz de confusão	Configurações 3 e 4: pesos > GAN
2	Métrica inadequada	Relatar recall e precisão **por classe**, F1 macro, acurácia balanceada e matriz de confusão; definir recall mínimo para COVID-19 antes da implantação; ajustar o	Recall por classe com intervalo de confiança	Caso original: 91% de acurácia ponderada e 40% de recall

#	Problema	Ação proposta	Métrica de verificação	Evidência neste trabalho
		limiar de decisão na curva precisão-recall		
3	Divisão sem estratificação e sem teste independente	Divisão estratificada e **por paciente**, treino, validação e teste independentes, teste usado uma vez; múltiplas sementes ou validação cruzada	Desvio padrão entre sementes e IC do recall	Teste real de 300 imagens por classe; variação entre sementes de até 0,18
4	Sem pré-treinamento / overfitting	Transfer learning (ImageNet ou modelos pré-treinados em radiografias); regularização	Recall no teste; gap treino-validação	Config. 2 vs 1: +32,9 p.p.
5	Sem augmentation	Augmentation clinicamente plausível (rotação, zoom, brilho e contraste; sem espelhamento); GAN apenas como complemento validado	Recall e estabilidade entre sementes	Incluída no pipeline melhorado
6	Otimização pobre	AdamW com *one-cycle* e cosseno, seleção do melhor checkpoint por acurácia balanceada e early stopping	Curva de validação por época; reprodutibilidade	Incluída no pipeline melhorado
7	Atalhos espúrios	Validação **externa** (outro hospital ou equipamento), mapas de saliência (Grad-CAM) para confirmar que o modelo olha para os pulmões, harmonização de contraste, documentar a origem de cada classe; testar também se artefatos de GAN viram atalho	Desempenho em dados de outra fonte; saliência em regiões pulmonares	Não testado (exige dados externos)

Riscos das imagens sintéticas: elas nunca devem entrar na validação ou no teste (aqui foram usadas só no treino); podem memorizar o treino ou colapsar em poucos modos (checado: sem memorização e com diversidade de ~84%); não substituem validação clínica nem a coleta de casos reais; e seus artefatos podem se tornar um atalho novo, motivo pelo qual o teste deve ser exclusivamente real.

Limitações. (i) Apenas 3 sementes por configuração, o que não permite concluir sobre diferenças menores que ~10 p.p. no recall; (ii) imagens em 64×64; (iii) o dataset não traz identificador de paciente, então não é possível garantir a separação por paciente; (iv) as classes do dataset vêm de fontes distintas, o que favorece atalhos; (v) uma única configuração da GAN (480 sintéticas) e uma única arquitetura de classificador; (vi) o desempenho em dados de outro

hospital não foi medido.

Conclusão do estudo de caso. O projeto original falhava por problemas de metodologia (métrica, desbalanceamento, ausência de pré-treino e de augmentation) e a correção de pipeline, mais os pesos de classe, recuperou grande parte do recall (de 40% para 73 a 78%). A cGAN, tecnicamente estável e sem memorização, **não trouxe ganho** de recall neste experimento e piorou-o em média, o que é um resultado relevante: gerar imagens não substitui dados reais, e toda técnica de augmentation sintética precisa ser validada em um teste real e estratificado antes de ser adotada.

Atividade 4.2: Transfer learning para análise de tráfego urbano

4.2.1 Definição do problema

Um grupo construiu um sistema que classifica câmeras urbanas como “livre”, “moderado” ou “congestionado”, com **ResNet-50 pré-treinada no ImageNet** e fine-tuning em **800 frames rotulados de 12 câmeras**. A acurácia de validação foi de 78% e o sistema foi implantado; em produção surgiram falhas sistemáticas em **chuva, período noturno e câmeras com ângulos ausentes do treino**. Esta seção identifica os problemas técnicos e metodológicos, seus impactos operacionais e como cada um seria abordado (sem implementação).

4.2.2 Problemas identificados, impactos e abordagem

1. Mudança de domínio entre o ImageNet e a cena de tráfego. O ImageNet ensina a reconhecer *objetos* centrais, nítidos e bem enquadrados. A tarefa aqui é estimar *densidade e fluxo* de dezenas de veículos pequenos, parcialmente ocluídos, em câmeras de baixa resolução e grande angular. O ResNet-50 redimensionado para 224×224 reduz carros distantes a poucos pixels, e as features de alto nível herdadas (cães, objetos domésticos) pouco ajudam. *Impacto:* confusão sistemática entre “moderado” e “livre” em cenas com veículos pequenos e distantes. *Abordagem:* trabalhar com maior resolução ou recortes por região de interesse (a via); descongelar mais camadas com LR menor no backbone; considerar modelos pré-treinados em tráfego (detectores como YOLO ou DETR treinados em COCO/UA-DETRAC) e estimar a **contagem de veículos e a ocupação** da via como característica intermediária, em vez de classificar a imagem inteira.

2. Dataset pequeno e pouco diverso para um modelo grande. 800 frames de 12 câmeras (≈67 frames por câmera) para ajustar um modelo de ~25 milhões de parâmetros, com frames de uma mesma câmera altamente correlacionados. *Impacto:* overfitting ao cenário de cada câmera (o modelo memoriza o fundo, o ângulo e a iluminação, e não o tráfego). *Abordagem:* aumentar e diversificar os dados (mais câmeras, horários, climas e estações); **augmentation fotométrica e geométrica** direcionada (brilho, contraste, ruído, simulação de chuva e neblina, mudanças de perspectiva e recortes), congelar a maior parte do backbone ou usar *feature extraction* com regularização forte, e aprendizado semi-supervisionado com frames não rotulados abundantes.

3. Validação que não mede o que acontece em produção (vazamento e métrica única). A acurácia de 78% parece ter sido medida em frames aleatórios das mesmas 12 câmeras, de modo que frames quase idênticos (do mesmo minuto e da mesma câmera) caem no treino e na validação. Além disso, só foi reportada a acurácia global, sem desempenho por classe, câmera e condição. *Impacto:* estimativa otimista, sem aviso de que o sistema falharia em câmeras novas e em chuva e à noite; o 78% não é nem confiável nem suficiente para uma decisão de implantação. *Abordagem:* **divisão por câmera** (validação com câmeras inteiras fora do treino, ou *leave-one-camera-out*) e por período; separar um conjunto de teste de **câmeras e condições novas**; reportar matriz de confusão, recall por classe e **métricas por subgrupo** (dia/noite, seco/chuva, ângulo), com intervalos de confiança.

4. Cobertura insuficiente de condições (covariate shift): chuva, noite e novos ângulos. O treino não contém (ou contém pouco) chuva, noite e ângulos novos; o modelo aprendeu a distribuição visual do dia seco das 12 câmeras. Faróis, reflexos no asfalto molhado, gotas na lente e baixa luminosidade alteram a aparência de forma que o modelo nunca viu. *Impacto operacional:* as falhas ocorrem justamente quando a informação é mais valiosa (a chuva e o horário de pico aumentam o congestionamento), levando a alertas errados, semáforos adaptativos mal ajustados, rotas sugeridas ruins e perda de confiança dos operadores. *Abordagem:* coletar e rotular dados nessas condições (priorizando os casos de falha observados em produção, o chamado *active learning*), usar augmentation sintética de clima e iluminação, adaptação de domínio (por exemplo, *test-time adaptation* ou normalização por câmera) e estabelecer **requisitos mínimos por condição** antes de qualquer implantação.

5. Formulação do problema: um frame estático e rótulos ordinais tratados como nominais. "Livre", "moderado" e "congestionado" dependem de **velocidade e movimento**, e não só de densidade: veículos estacionados ou um semáforo vermelho curto produzem imagens parecidas com as de um congestionamento. Além disso, as classes são **ordinais** e o rótulo "moderado" é subjetivo, mas a entropia cruzada trata um erro "livre → congestionado" igual a um erro "livre → moderado". *Impacto:* confusão estrutural entre classes, ruído de rótulo na fronteira e erros graves tratados como leves. *Abordagem:* usar **sequências de frames** (ou fluxo óptico) para capturar movimento, estimar velocidade média e contagem com detecção e rastreamento (YOLO e tracker), definir os rótulos por critérios objetivos (limites de velocidade e ocupação), usar perda ordinal e avaliar com métricas que penalizam o erro por distância (erro absoluto ordinal).

6. Implantação sem monitoramento, calibração e plano de contingência. O sistema foi implantado com base em uma única métrica de validação e sem acompanhamento posterior. *Impacto:* a degradação é descoberta apenas por reclamações; não há como distinguir um erro do modelo de uma câmera defeituosa e o modelo não indica incerteza. *Abordagem:* monitoramento contínuo (distribuição das entradas e das previsões, taxa de baixa confiança), **calibração das probabilidades** e rejeição por incerteza (encaminhar casos duvidosos a um operador humano), amostragem periódica com rotulagem manual para medir a acurácia real, detecção de *drift* por câmera e *rollback* para a regra anterior; versionar dados e modelo e retreinar com os casos de falha.

4.2.3 Plano resumido

Etapa	Ação	Problema que resolve
1	Reorganizar a avaliação: divisão por câmera e por período, métricas por classe e condição	3
2	Medir o desempenho atual em câmeras novas, chuva e noite para quantificar a lacuna	3, 4
3	Coletar e rotular dados dos casos de falha; ampliar o número de câmeras	2, 4
4	Mudar a formulação: detecção, rastreamento e contagem, mais velocidade e rótulos ordinais objetivos	1, 5
5	Augmentation de clima e iluminação; fine-tuning parcial com LR menor no backbone	1, 2, 4
6	Calibração, rejeição por incerteza, monitoramento de *drift* e plano de contingência	6

Em resumo, o transfer learning do ImageNet *parece* direto, mas o problema real exige adaptar a **formulação** (movimento e contagem), os **dados** (diversidade de câmeras e condições) e a **avaliação** (por câmera e condição) antes de confiar no modelo em produção.

Conclusões gerais

- **Pré-treino e transferência** foram o fator dominante nas três atividades experimentais: no A1, o ViT-B/16 pré-treinado superou o ViT do zero em 10,75 p.p.; no A3, apenas 0,06% dos parâmetros treinados (feature extraction) bastaram para 98,89% de acurácia; no A2, o CLIP funcionou sem treino algum.
- **Arquitetura é uma decisão de projeto, não um padrão:** no A1, a ResNet-18 chegou perto do ViT-B/16 com uma fração do custo; a escolha depende de dados, custo e domínio.
- **Interpretar é tão importante quanto medir:** a atenção bruta do ViT-B/16 aponta para o fundo, enquanto o *rollout* mostra o objeto; no CLIP, um score alto não prova a presença do conceito; no A3, o erro de uma ilustração revela mudança de domínio.
- **Dados sintéticos exigem validação:** no 4.1 a cGAN foi estável e não memorizou, mas **não melhorou o recall** de COVID-19 (66,1% contra 73,0% sem sintéticas e 77,9% com pesos de classe), enquanto o pipeline melhorado elevou o recall de 40,1% para 73,0%.
- **Metodologia de avaliação:** os estudos de caso 4.1 e 4.2 mostram que acurácia global, divisões não estratificadas, vazamento entre amostras e ausência de teste em condições reais produzem sistemas que “funcionam” no papel e falham na prática.

Referências

- Dosovitskiy, A. et al. (2021). *An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale.* ICLR.
- Vaswani, A. et al. (2017). *Attention Is All You Need.* NeurIPS.
- Devlin, J. et al. (2019). *BERT: Pre-training of Deep Bidirectional Transformers for*

Language Understanding. NAACL.
- Touvron, H. et al. (2021). *Training data-efficient image transformers & distillation through attention (DeiT).* ICML.
- Liu, Z. et al. (2021). *Swin Transformer: Hierarchical Vision Transformer using Shifted Windows.* ICCV.
- Abnar, S.; Zuidema, W. (2020). *Quantifying Attention Flow in Transformers.* ACL.
- Radford, A. et al. (2021). *Learning Transferable Visual Models From Natural Language Supervision (CLIP).* ICML.
- Roffo, G.; Vinciarelli, A. (2016). *Personality in Computational Advertising: A Benchmark.* EMPIRE, ACM RecSys.
- He, K. et al. (2016). *Deep Residual Learning for Image Recognition.* CVPR.
- Nour, M.; Tariq, M. (2023). *Scientific Reports.* https://www.nature.com/articles/s41598-023-37743-4
- Chowdhury, M. E. H. et al. (2020). *Can AI help in screening Viral and COVID-19 pneumonia?* IEEE Access, 8.
- Rahman, T. et al. (2021). *Exploring the effect of image enhancement techniques on COVID-19 detection using chest X-ray images.* Computers in Biology and Medicine, 132.
- Goodfellow, I. et al. (2014). *Generative Adversarial Nets.* NeurIPS. Mirza, M.; Osindero, S. (2014). *Conditional GANs.* arXiv:1411.1784. Radford, A.; Metz, L.; Chintala, S. (2016). *DCGAN.* ICLR. Miyato, T. et al. (2018). *Spectral Normalization for GANs.* ICLR. Zhao, S. et al. (2020). *Differentiable Augmentation for Data-Efficient GAN Training.* NeurIPS.
- Meegle. *Transfer learning for traffic analysis.* https://www.meegle.com/en_us/topics/transfer-learning/transfer-learning-for-traffic-analysis
- Datasets (Kaggle): *Fashion Product Images (Small)* (P. Aggarwal); *ADS-16* (G. Roffo); *Images Dataset* (P. Sanagapati); *COVID-19 Radiography Database* (T. Rahman e M. Chowdhury). Modelos: `google/vit-base-patch16-224-in21k`, `openai/clip-vit-base-patch32` (Hugging Face).

Declaração de uso de IA

O assistente Claude (Anthropic) foi utilizado como apoio na estruturação do código e na revisão dos textos deste notebook